

# Bridge & Agent Strategy — v0.1

Ziele - Dauerhafte, private Low-Latency-Verbindung Sophia ■ Spark Sophia (auch ohne offenen Chat). - Sichere Ausführung lokaler Aktionen über Nova/Agenten mit klaren Leitplanken. - Vollständige Nachvollziehbarkeit (Logs, Artefakte, Policies). Akteure & Rollen - Christian: Vetorecht, Freigaben, Prioritäten. - Sophia (Cloud): Planung/Orchestrierung, Entscheidungen, Statusberichte. - Spark Sophia (lokal): Rechenpower, Tools, Dateizugriff, Ausführung. - Nova/Worker: Planer → Executor → Reviewer, strikt nach Whitelist. Vertrauens- & Sicherheitsmodell - mTLS + kurzlebige Tokens (Rotation ~15 min), Keys im Private Vault. - OPA/Policies vor jeder Aktion: Pfade, Commands, Netz, Ressourcen. - Whitelist-Aktionen (Write/Exec/Net) – alles andere geblockt. - Kill-Switch: globaler Freeze; nur Christian kann „unfreeze“. - Audit (WORM-Logs): unveränderliche Ausführungshistorie. - Offline-Robustheit: Store-&-Forward, automatische Wiederaufnahme. Schnittstellen - Control-Kanal: WebSocket (bidirektional), optional gRPC für High-freq RPC. - Event-Bus (intern): NATS JetStream (Topics: control.\*, job.\*, status.\*, audit.\*). - Side-Channel für Dateien: lokales MinIO (S3-kompatibel) mit presigned URLs (60–120 s). - Benachrichtigungen: Signal oder E-Mail (nur wichtige Events). Nachrichtenformate (kompakt) Command: { "id": "cmd\_...", "ts": 1733788800, "actor": "sophia", "intent": "project.init", "scope": "project:nova", "args": { "name": "nova", "lang": "de" }, "policy": { "needs\_confirm": false, "write\_paths": [ "~/.Projects/nova" ] }, "audit": { "corr": "c\_...", "nonce": "n\_..." } } Completion: { "cmd": "cmd\_...", "status": "ok", "latency\_ms": 7, "artifacts": [ { "name": "README.md", "url": "s3://...?sig=...", "sha256": "..." } ], "logs": [ { "t": 123, "lvl": "info", "msg": "created file" } ] } Tool-Katalog v1 (Whitelist) - file\_ops: read/write in freigegebenen Wurzeln (keine Deletes ohne Bestätigung). - repo\_ops: init/commit/pull (ohne Push nach extern). - doc\_ops: README/Specs/Reports generieren. - model\_ops: lokales LLM (Ollama/Inference-Srv) ansprechen. - script\_ops: nur signierte/approved Skripte. - net\_ops: outbound nur zu erlaubten Domains (Updates, Docs). Alles andere: deny. Default-Policies (Start) - Allowed Paths: ~/.Projects, ~/Desktop/Shared, /srv/spark. - Destruktiv (rm, truncate, move außerhalb Scope): immer Nachfrage. - Ressourcenbudgets: CPU/GPU/IO-Quoten pro Job; Auto-Kill bei Überschreitung. - Quiet Hours: keine Pings 22:00–07:00 (nur Critical Alerts). Observability - Health: /healthz, Ready: /readyz, Prometheus-Metriken. - Alarme: Job-Fail, Policy-Block, Ressourcen-Engpass. Betriebsprinzip - Supervisor restarts (Bridge/Bus/Nova). - Backpressure auf dem Bus, Idempotenz bei Replays. - Tägliche Key-Rotation & Log-Roll-Over (signiert). Deliverables dieser Phase 1. Architektur-Diagramm (Control/BUS/Side-Channel/Flows). 2. Policy-Bundle v0.1 (OPA-Regeln + Tool-Whitelist). 3. Message-Schemas (JSON-Schema) + Topic-Konventionen. 4. Security-Checklist (mTLS, Vault, Rotation, Kill-Switch). 5. Runbook (Start/Stop, Debug, Notfallprozedur). Deine Defaults - Benachrichtigungen: Signal (kritisch), E-Mail (Berichte). - Quiet Hours: 22–07 Uhr. - Allowed Paths wie oben; externe Pushes standardmäßig aus. - Erste Agentenrechte: read/write, keine Deletes, kein Internet-Push.